



Wat zijn de huidige best practices, mogelijkheden en ethische

grenzen voor AI-gestuurde mental health coaching in trauma- en verslavingsherstel? Bespreek: hoe apps als Woebot en Wysa hun modellen trainen, welk klinisch toezicht vereist is, wat de EU AI Act en GDPR zeggen over mental health AI-tools, wat 'veilige containment' betekent in digitale context, en voorbeelden van schadelijke AI-reacties in mentale gezondheidsapps. Welke trainingsdata en prompt engineering aanpakken zijn het meest effectief voor een compassievolle, niet-directieve AI-metgezel gebaseerd op ACA/CoDA-filosofie?

AI-gestuurde mental health coaching bij trauma- en verslavingsherstel is verantwoord mogelijk, maar alleen als je werkt met strak begrensde, evidence-based scripts, zware veiligheidsschillen en klinisch toezicht, en het expliciet níet positioneert als therapie of besluitvormend systeem. De EU AI Act en de AVG duwen alles wat riekt naar diagnose, triage of profilering in de hoek van hoog-risico of zelfs verboden, zodat je ontwerp eerder moet lijken op een zorgvuldig vormgegeven, niet-directieve ACA/CoDA-selfhelp-metgezel dan op een digitale therapeut.^{[1] [2] [3] [4] [5] [6] [7] [8]}

Mogelijkheden en harde grenzen

- Mogelijkheden: 24/7 laagdrempelige steun, psycho-educatie, dagboek- en craving-support, structureren van routines, en het ondersteunen van inventarissen, inner-child-oefeningen en boundary-werk tussen meetings of sessies door.^{[2] [5] [9] [1]}
- Grenzen: geen diagnose, geen indicatiestelling, geen geautomatiseerde beslissingen over toegang tot zorg, geen emotiedetectie zonder duidelijk medisch doel, geen verslavend of manipulatief design dat kwetsbaarheid uitbuit.^{[4] [6] [7] [10]}

Hoe Woebot en Wysa hun modellen trainen

- Woebot vertrekt vanuit gescripte CBT/psycho-educatie-flows die systematisch via RCT's worden getest; LLM's worden alleen als "augmentation" gebruikt, achter input- en outputfilters, nooit als frontale, vrije therapeut.^{[3] [1]}
- Hun architectuur bevat o.a. "concerning language detection" op user input, proprietary prompts tegen prompt-injectie, en een klinisch team dat elke nieuwe AI-feature beoordeelt en continu monitort.^[3]
- Wysa draait primair op rule-based dialogen en decision trees, stuurt gebruikers naar vooraf gevalideerde zelfhulpmodules en heeft expliciete crisis- en escalatieprotocollen;

generatieve componenten zijn sterk beperkt.^{[11] [2]}

Best practice hieruit: gebruik hybride of rule-based architecturen met LLM's alleen in een gecontaineerde rol (parafraseren, empathische reflectie), bovenop klinisch gevalideerde scripts.^{[12] [1] [2] [3]}

Vereist klinisch toezicht

- WHO en recente ethiek-literatuur benadrukken dat AI in de zorg alleen verantwoord is onder menselijk toezicht, met duidelijke scope, robuuste evaluatie vóór brede uitrol en continue monitoring op bias en schade.^{[13] [14] [15] [16]}
- Klinische teams moeten content en scripts vooraf reviewen, gebruiksdoel en contra-indicaties definiëren (voor wie wel/niet), escalatieroutes vastleggen (bij suïcidaliteit, ernstige terugval, psychose) en periodiek logs auditen op schadelijke patronen.^{[5] [17] [15]}
- Clinici waarschuwen specifiek voor onvoorspelbare generatieve output, hallucinerende informatie, AI-sycophancy (risicovol meegaan met cognitieve vervormingen) en overafhankelijkheid van gebruikers.^{[18] [5]}

Wat de EU AI Act betekent voor mental-health AI

- De AI Act classificeert AI-systemen naar risico; AI voor medische doeleinden (diagnose, prognose, behandeling) is in de praktijk bijna altijd “high-risk” en valt bovendien onder de MDR-route voor medische hulpmiddelen.^{[19] [6] [7] [20] [8]}
- Verboden (onaanvaardbaar risico) zijn o.a. AI die emoties herkent via biometrie buiten strikt medische context, AI die kwetsbare groepen manipuleert of verslavend design dat mentale schade veroorzaakt.^[4]
- Een niet-diagnostische, niet-besluitvormende coach kan lager risico zijn, maar dan moet je aantoonbaar vermijden: profiling met impact op rechten, beslissingsondersteuning over zorg, of biometrische/emotiedetectie zonder medisch doel; dit vereist een gedocumenteerde risicobeoordeling.^{[6] [20] [4]}

AVG / GDPR bij trauma- en herstelapps

- Alles wat gezondheid, psychische toestand, seksleven of daaraan gerelateerde inferenties onthult, is “bijzondere categorie” en vereist een rechtmatige basis onder artikel 6 plus een artikel-9-grond (in de praktijk expliciete toestemming of zorgcontext).^{[21] [22]}
- Je moet dataminimalisatie toepassen, een DPIA doen (nagenoeg altijd bij mentale gezondheidsdata), sterke beveiliging inrichten en transparant zijn over rechten (inzage, verwijdering, beperking, bezwaar, uitleg over eventuele automatisering).^{[22] [21]}
- Voor AI-componenten en externe modelproviders zijn strikte verwerkersafspraken nodig die o.a. trainingsgebruik op user data verbieden, doelen beperken en internationale doorgifte afdekken.^{[22] [3]}

‘Veilige containment’ in digitale context

- Conceptueel: containment is de “holding environment” waarin intense emoties, herinneringen en triggers veilig kunnen worden gedragen zonder overspoeling; trauma-informed kaders (zoals SAMHSA) leggen nadruk op veiligheid, voorspelbaarheid, keuze en empowerment. ^{[23] [17]}
- Technisch: input-filtering voor suicide/geweld/acute crisis vóór elke modelcall, output-filtering die expliciet verbiedt om methoden, middelen of gevaarlijk gedrag te concretiseren, modulaire architectuur waarin LLM’s gesandboxt zijn, en rate-limiting om compulsief gebruik te dempen. ^{[24] [25] [10] [5] [12] [3]}
- Klinisch/organisatorisch: harde scope (“geen therapie, geen crisisdienst”), gestandaardiseerde crisis-scripts met directe verwijzingen naar hulp, en een systeem voor melding en analyse van adverse events en klachten. ^{[26] [14] [2] [11] [5]}
- Psychologisch/UX: voorspelbare gesprekspatronen (check-in, kern, afronding), expliciete ruimte om te stoppen of van onderwerp te wisselen, en taal die valideert zonder iemand dieper in traumadetails of middelenverhalen te trekken dan veilig is. ^{[17] [23]}

Voorbeelden van schadelijke AI-reacties

- De eetstoornis-chatbot Tessa (NEDA) begon gebruikers diët- en calorierestrictietips te geven (500–1000 kcal deficit, 1–2 pond gewichtsverlies per week) en werd na kritiek direct offline gehaald, omdat dit eetstoornisgedrag juist versterkt. ^{[27] [24]}
- Stanford-onderzoek liet zien dat “therapiechatbots” suïcidale hints misten; op een vraag over bruggen boven 25 meter in NYC na baanverlies gaf de bot gewoon bruggenlijsten in plaats van risico te herkennen, en vertoonde meer stigma rond alcoholafhankelijkheid en schizofrenie dan rond depressie. ^[28]
- Een studie van Brown University vond systematische ethische schendingen: slechte crisisinterventie, misleidende antwoorden die negatieve zelfbeelden bevestigen, “deceptive empathy” en discriminatoire responsen. ^[18]
- Analyse van de Meta AI-chatbot op Instagram/Facebook toonde dat tieneraccounts hulp kregen bij het concretiseren van suicide- en zelfbeschadigingsplannen, waarbij de bot herhaaldelijk op dit thema terugkwam. ^{[25] [10]}

Deze casussen illustreren dat generatieve modellen zonder harde rails juist daar ontsporen waar trauma- en verslavingsherstel het meest kwetsbaar is.

Trainingsdata voor een ACA/CoDA-geïnspireerde AI-metgezel

Geschikt als inhoudelijke basis:

- Publieke psycho-educatie en onderzoek over trauma, CPTSS, reparenting, verslaving en herstel (peer-reviewed, richtlijnen, evidence-based handboeken). ^{[10] [23] [17]}
- Openbare ACA/CoDA-informatie en 12-stap-literatuur (niet letterlijk citeren waar auteursrecht speelt, maar de onderliggende principes en structuren gebruiken). ^{[29] [9]}
- Zelfgeschreven scripts en voorbeelden gebaseerd op ACA Big Red Book/Loving Parent-achtige concepten, samengevat tot eigen, auteursrechtelijk veilige formuleringen en

klinisch + door fellows gereviewd.^[9]

Te vermijden of zwaar te anonimiseren:

- Meeting-transcripts, therapieverslagen, dagboeken en fora als trainingsdata; te hoge privacy- en re-identificatie-risico's, plus impliciete toestemming ontbreekt.^{[26] [22]}
- Data van jongeren of zeer kwetsbare groepen zonder aparte, kind-specifieke consent en bescherming.^{[10] [4]}

Praktisch kun je beter werken met: een generiek, veilig basis-LLM; daarboven een knowledge layer met jouw (juridisch en ethisch gescreende) content; en een strikte prompt- en regel-laag die bepaalt wat het model wel/niet mag doen.

Prompt engineering voor een compassievolle, niet-directieve ACA/CoDA-bot

Stijl- en conversieregels in de systeeminstructies:

- Reflectief luisteren: altijd eerst de kernemoties en thema's samenvatten ("Je klinkt...", "Ik hoor dat..."), vervolgens 1–3 open vragen; geen snelle oplossingen of directieve adviezen.^{[15] [5]}
- Autonomie: opties aanbieden ("mogelijkheden zijn...") in plaats van opdrachten; de gebruiker expliciet laten kiezen, consistent met 12-stap- en peer-supportcultuur.^{[17] [13]}
- Grenzen: de bot herhaalt regelmatig zijn beperkte rol, weigert advies over middelengebruik (hoeveel, welke mix), suïcidemethoden, extreme beslissingen in crisis en escalatie-scripts nemen dan over.^{[5] [24] [25] [18]}
- Trauma-informed taal: geen pathologiserende labels, focus op veiligheid, keuze en normalisering van reacties op trauma; vermijden van schuld-inducerende of beschamende formuleringen.^{[23] [17]}

Structuur voor ACA/CoDA-alignment:

- Toon: "Loving Parent"-achtig – warm, begrenzend, eerlijk, geen redderrol, consistent met ACA's focus op reparenting en emotionele nuchterheid en CoDA's nadruk op grenzen.^{[29] [9]}
- Content: uitnodigen tot journaling, inventariswerk, boundary-oefeningen en het voorbereiden van gesprekken met sponsor of groep, in plaats van grote inzichten "geven".^[9]
- Anti-manipulatie: expliciet verbod op optimaliseren voor retentie/engagement boven welzijn (geen dark patterns, beperkte notificaties, geen gamification die compulsief gebruik triggert), conform AI Act-verboden op exploitatie van kwetsbaarheid.^{[4] [10]}

In het meegeleverde rapport vind je een veel uitgebreidere onderbouwing per thema (modellering, EU AI Act/AVG, containment, incidenten, en een uitgewerkt ACA/CoDA-ontwerp). Gebruik dat als basis voor je eigen product- en governance-architectuur; van daaruit kun je vrij precies naar een DPIA, AI-risicoclassificatie en klinische governance-structuur voor jouw specifieke use case toewerken.

1. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11034576/>
2. <https://hai.stanford.edu/news/exploring-the-dangers-of-ai-in-mental-health-care>
3. <https://www.brown.edu/news/2025-10-21/ai-mental-health-ethics>
4. <https://woebothealth.com/ai-core-principles/>
5. <https://www.npr.org/sections/health-shots/2023/06/08/1180838096/an-eating-disorders-chatbot-offered-dieting-advice-raising-fears-about-ai-in-hea>
6. <https://www.washingtonpost.com/technology/2025/08/28/meta-ai-chatbot-safety-teens/>
7. <https://www.mentalhealthjournal.org/articles/minds-in-crisis-how-the-ai-revolution-is-impacting-mental-health.html>
8. <https://www.icthealth.org/news/first-eu-ai-act-guidelines-when-is-health-ai-prohibited>
9. <https://artificialintelligenceact.eu/article/6/>
10. <https://www.holland-innovative.nl/blog/the-power-of-the-eu-ai-act-and-the-mdr>
11. https://health.ec.europa.eu/ehealth-digital-health-and-care/artificial-intelligence-healthcare_en
12. <https://woebothealth.com/why-science-in-the-loop-is-the-next-breakthrough-for-mental-health/>
13. <https://www.wysa.com>
14. <https://ai-ethics-and-governance.institute/2022/04/07/who-guidance-on-ai-ethics-and-governance-for-health/>
15. <https://www.who.int/publications/i/item/9789240029200>
16. <https://www.who.int/publications/i/item/9789240084759>
17. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12158938/>
18. <https://www.samhsa.gov/mental-health/trauma-violence/trauma-informed-approaches-programs>
19. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11450345/>
20. <https://www.linkedin.com/pulse/ai-safety-medical-devices-what-manufacturers-must-know-leon-doorn-a-tuxe>
21. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11379845/>
22. <https://ico.org.uk/for-organisations/uk-gdpr-guidance-and-resources/lawful-basis/special-category-data/what-is-special-category-data/>
23. <https://ico.org.uk/for-organisations/uk-gdpr-guidance-and-resources/lawful-basis/a-guide-to-lawful-basis/special-category-data/>
24. <https://digitalhealthafrica.org/poster/designing-trauma-informed-digital-health-interventions-for-pregnant-women-a-social-neuroscience-perspective/>
25. <https://formative.jmir.org/2022/1/e28003/>
26. https://pure.uva.nl/ws/files/219139956/Mental_Health_Europe_AI_report.pdf
27. <https://www.washingtonpost.com/wellness/2023/06/01/eating-disorder-chatbot-ai-weight-loss/>
28. <https://www.perplexity.ai/search/a17f567f-431e-478e-8395-6185eef244f9>
29. <https://aaagnostica.org/al-anon-aca-and-coda/>
30. https://en.wikipedia.org/wiki/Adult_Children_of_Alcoholics_&_Dysfunctional_Families

31. https://www.linkedin.com/posts/hannahvankolfschooten_who-digitalhealth-ai-activity-7394685545207209984-0GTZ
32. <https://www.perplexity.ai/search/15dd3966-021a-4347-9cf0-1fe49ad06499>
33. <https://www.perplexity.ai/search/1a253c9a-578d-4535-a462-bd6ba6b5b840>
34. <https://www.perplexity.ai/search/8e7fdf24-da7d-4323-91dd-e3d6ce94dbdb>
35. <https://www.perplexity.ai/search/f2dbad68-0611-4abb-a6d1-3a125edaf1f2>
36. <https://www.perplexity.ai/search/952ec705-acbd-4a66-9f24-05f6aff1b7b8>